

ESCUELA:

Tecnológico Nacional de México campus Culiacán

Carrera:

Ingeniería en Sistemas Computacionales

Materia:

Tópicos de Inteligencia Artificial

Profesor(a):

Zuriel Dathan Mora Felix

Nombre de la tarea:

Proyecto de Investigación de inteligencia artificial e impacto ambiental

ALUMNOS:

22170574 Bejarano Ureta Sebastián

22170861 Garcia Inzunza Kevin Alejandro

FECHA:

17/09/2026

Culiacán Sinaloa

Predicción de Parámetros Físico-Químicos Críticos (WQI) mediante Redes Neuronales Recurrentes (LSTM) en Sinaloa

1. Introducción

Contexto del área de estudio y problemática ambiental: Sinaloa es uno de los motores agroindustriales más importantes de México, cuya viabilidad económica y social depende de una compleja red hídrica integrada por 11 ríos principales y extensas cuencas hidrográficas. Sin embargo, este desarrollo ha generado una presión ambiental severa sobre la calidad del agua debido al escurrimiento de agroquímicos, descargas residuales urbanas sin tratar y la filtración de pasivos mineros en las zonas altas de la Sierra Madre Occidental.

Limitaciones del monitoreo tradicional del agua: El monitoreo tradicional de estos cuerpos de agua mediante estaciones fijas de medición física resulta insuficiente: los equipos sufren bioincrustaciones y desgaste acelerado, los costos de operación en zonas geográficas complejas son elevados y las pruebas de laboratorio introducen desfases temporales que impiden actuar ante emergencias ambientales.

Propuesta de Inteligencia Artificial (concepto de sensores virtuales con LSTM): Frente a esta problemática, las técnicas de Aprendizaje Profundo (Deep Learning) ofrecen una alternativa disruptiva. En particular, las redes neuronales de Memoria a Corto y Largo Plazo (LSTM) poseen la capacidad de modelar la inercia hidrológica, la no linealidad ambiental y los desfases temporales (time-lags) característicos de las cuencas. Esta investigación propone el desarrollo de un marco predictivo basado en LSTM que funciona bajo el paradigma de "sensores virtuales", estimando el comportamiento de variables críticas como oxígeno disuelto (OD), pH, turbidez y concentración de metales pesados a partir de un conjunto reducido de parámetros de entrada y mediciones ambientales.

2. Objetivos

Objetivo General

- Desarrollar un sistema de estimación y proyección temporal del Índice de Calidad del Agua (WQI) mediante el entrenamiento de redes neuronales recurrentes (LSTM) para predecir parámetros físico-químicos críticos en cuencas hídricas con baja densidad de sensores físicos.

Objetivos Específicos

- Modelar la dinámica temporal de variables físico-químicas críticas como Potencial de Hidrógeno (pH), Oxígeno Disuelto (OD), Conductividad Eléctrica (CE), Turbidez, Temperatura y Demanda Bioquímica de Oxígeno (DBO).
- Imputar variables faltantes y discontinuas a partir de datos meteorológicos, hidrológicos y de escorrentía para mitigar fallas en la recolección de datos in situ.
- Comparar el desempeño predictivo de la arquitectura LSTM frente a modelos basados en árboles como XGBoost utilizando métricas estandarizadas de error.
- Integrar las predicciones de los parámetros en el cálculo dinámico del WQI para habilitar un esquema de alerta temprana y soporte en la toma de decisiones ambientales.

3. Justificación

Reducción de costos operativos y mantenimiento de hardware: El modelo sustituye la necesidad de desplegar redes densas de hardware costoso mediante el uso de sensores virtuales software. Esto reduce los gastos recurrentes en calibración, insumos químicos, reactivos y mantenimiento técnico in situ.

Monitoreo y cobertura en zonas remotas o de difícil acceso: Permite extender la cobertura de vigilancia hacia los tramos de difícil acceso en la sierra o drenes agrícolas periféricos utilizando una red mínima de nodos IoT sustentables, superando las barreras geográficas que históricamente han dejado a estas zonas sin supervisión.

Eficiencia frente a datos incompletos o discontinuos: La arquitectura LSTM supera las limitaciones de la estadística lineal convencional al imputar datos faltantes por fallas de transmisión y predecir variaciones físico-químicas antes de que ocurran, gestionando con precisión la latencia inherente a los procesos hidrológicos.

Impacto ambiental y toma de decisiones preventiva: Al ofrecer estimaciones en tiempo real del Índice de Calidad del Agua (WQI), la herramienta transforma la gestión hídrica de un enfoque reactivo a uno preventivo, permitiendo a las autoridades mitigar el impacto de derrames o picos de contaminación antes de que causen daños irreversibles en los ecosistemas acuáticos y la salud pública.

4. Alcance

Alcance geográfico (cuerpos de agua / cuencas / acuíferos): Cuencas y cuerpos de agua del estado de Sinaloa con énfasis en tramos fluviales, drenes agrícolas y zonas con baja densidad de instrumentación física.

Alcance temporal (periodos de registro considerados): Series de tiempo continuas e intermitentes que contemplen variaciones estacionales (períodos de estiaje y temporadas de lluvia/escorrentía).

Alcance técnico y límites del proyecto: Desarrollo centrado en software y modelado analítico mediante Python, utilizando librerías como Pandas, Scikit-learn, XGBoost y Statsmodels/TensorFlow/PyTorch. El alcance se limita a la estimación, imputación y pronóstico algorítmico, operando bajo el paradigma de sensores virtuales sin incluir la fabricación de prototipos de hardware de sensado físico.

5. Desarrollo

5.1. Paso 2: Hallazgos de Investigación y Estado del Arte

Parámetros físico-químicos analizados:

- Potencial de Hidrógeno (pH): Indica si el agua es ácida o alcalina; ayuda a saber la estabilidad química general del agua.
- Sólidos Disueltos Totales (SDT): Refleja la cantidad total de minerales y sales disueltas en el agua; un valor alto indica exceso de sales o contaminación.
- Dureza Total: Mide la concentración conjunta de sales de calcio y magnesio disueltas.
- Calcio y Magnesio : Minerales naturales del suelo y rocas que determinan qué tan "dura" es el agua y su interacción con los mantos acuíferos.
- Nitratos : Nutriente químico directamente relacionado con el arrastre y filtración de fertilizantes agrícolas y aguas residuales.
- Cloruros : Sales minerales asociadas tanto a la geología como a la intrusión salina (agua de mar que entra a los pozos por sobreexplotación) y descargas residuales.
- Sulfatos : Compuestos derivados del uso de fertilizantes químicos y desechos industriales.
- Fluoruros : Mineral presente en formaciones rocosas subterráneas que en concentraciones elevadas puede representar un riesgo para la salud.
- Alcalinidad total: Mide la capacidad que tiene el agua para neutralizar ácidos de forma natural.

Comportamiento hidroquímico reportado en las fuentes consultadas:

1. Estabilidad del pH vs. Alta Dispersión Mineral

- **Comportamiento del pH:** Presenta una condición ligeramente alcalina y químicamente estable a nivel estatal, con promedios que oscilan entre 7.29 y 7.75 UpH y coeficientes de variación muy bajos (entre 3.17% y 6.30%).
- **Fluctuación de sales (SDT):** A diferencia del pH, los Sólidos Disueltos Totales exhiben una variabilidad severa. Los valores promedio estatales van desde 222.8

mg/L (Río Piaxtla) hasta picos de 1,007.98 mg/L (Río Mocorito) y 1,058.62 mg/L (Río Sinaloa).

2. Huella Antropogénica: Fertilizantes y Actividad Agrícola

- **Nitratos :** Muestran una dispersión extrema provocada por la lixiviación de fertilizantes sintéticos. El acuífero del Río Mocorito promedia 9.50 mg/L (con acuíferos presentando variaciones de hasta 157.7%), evidenciando cargas contaminantes intermitentes por escorrentía agrícola.
- **Sulfatos :** El acuífero del Río Mocorito alcanza concentraciones promedio de 168.4 mg/L con un coeficiente de variación de 103.4%, asociadas a insumos agrícolas y vertimientos industriales.

3. Anomalías y Picos Temporales Históricos (2012–2018)

- **Evento extremo de 2014:** Se registró un valor máximo histórico de SDT de 3,484 mg/L, derivado de eventos excepcionales de escorrentía superficial y fuentes de contaminación puntuales.
- **Sobreexplotación costera:** El abatimiento de los mantos freáticos por extracción intensiva para riego genera procesos acelerados de intrusión salina en zonas agrícolas adyacentes al litoral.

4. Diagnóstico del Índice de Calidad del Agua (WQI) por Acuífero

- **Calidad Excelente:** Río Piaxtla (36.12) y Río Baluarte (47.18), con baja carga mineral y contaminante.
- **Calidad Buena :** Río Fuerte (57.27), Río Elota (55.31) y Río Culiacán (78.29), este último sometido a alta presión agroindustrial y urbana.
- **Calidad Pobre:** Río Mocorito (103.66), clasificado en estado crítico debido a concentraciones elevadas de solutos inorgánicos y nutrientes.

Tabla 2. Resumen estadistico de los parámetros de calidad del agua utilizados en el WQI

PARÁMETRO	ESTADÍSTICA	RIO BALUARTE	RIO CULIACAN	RIO ELOTA	RIO FUERTE	RIO MOCORITO	RIO PIAXTLA	RIO PRESIDIO	RIO SAN LORENZO	RIO SINALOA
pH	Promedio	7.615	7.69507	7.53154	7.75441	7.60469	7.43081	7.29782	7.52452	7.65911
	Coeficiente de Variación	3.17%	4.43%	4.23%	5.39%	4.66%	6.27%	6.30%	3.77%	5.28%
SDT	Promedio	304.9	540.707	406.461	508.888	1007.98	222.828	306.263	406.874	1058.62
	Coeficiente de Variación	47.98%	40.21%	33.70%	54.89%	67.72%	32.54%	53.83%	29.81%	51.05%
Dureza Total	Promedio	181.881	278.86	223.997	193.569	465.939	139.852	144.519	261.136	559.965
	Coeficiente de Variación	61.35%	28.35%	22.64%	28.85%	69.29%	51.41%	49.66%	35.47%	56.55%
Calcio	Promedio	56.9055	80.0937	77.8428	49.8203	127.001	34.1517	40.1171	79.3459	168.507
	Coeficiente de Variación	56.57%	27.29%	26.89%	32.91%	83.30%	39.80%	49.96%	27.17%	60.46%
Magnesio	Promedio	17.4975	24.0164	15.1218	17.9409	45.9634	9.25914	11.1875	18.7779	38.8421
	Coeficiente de Variación	74.83%	35.72%	43.83%	40.85%	69.76%	57.36%	73.96%	35.48%	59.97%
Nitratos	Promedio	2.7215	3.7893	1.64282	2.51559	9.50578	0.928919	0.802222	5.45935	3.41444
	Coeficiente de Variación	83.15%	116.46%	82.22%	105.12%	63.91%	93.99%	157.77%	53.68%	75.96%
Cloruros	Promedio	33.5555	54.7433	96.0695	131.282	148.847	111.513	77.5713	84.101	48.7809
	Coeficiente de Variación	117.71%	152.44%	129.95%	162.39%	168.79%	142.59%	159.03%	107.58%	77.55%
Sulfatos	Promedio	35.0145	62.2322	23.0637	46.1585	168.406	21.582	35.0498	53.1155	139.253
	Coeficiente de Variación	55.87%	73.80%	91.98%	37.69%	103.41%	33.91%	69.91%	53.60%	91.83%
Fluoruros	Promedio	0.3	0.282	0.225556	0.519118	0.335	0.340811	0.310182	0.417097	0.288
	Coeficiente de Variación	55.74%	56.40%	34.40%	59.90%	37.56%	30.16%	53.07%	44.20%	58.26%
Alcalinidad	Promedio	174.053	273.567	232.175	253.219	379.242	131.886	154.61	226.756	252.78
	Coeficiente de Variación	64.46%	30.80%	19.61%	33.96%	25.25%	48.17%	47.99%	20.99%	31.21%

5. Impacto de Aguas Residuales (ARD Y ARA) y Riesgos Físico-Químicos

Estudios previos indican que los riesgos asociados a esta contaminación por Aguas Residuales Domésticas (ARD) y Agrícolas (ARA) son críticos cuando no hay un tratamiento o monitoreo previo. Un ejemplo histórico de este peligro ocurrió en 1993 en Wisconsin (EE.UU.), donde la escorrentía agropecuaria introdujo patógenos (Cryptosporidium spp.) resistentes a los sistemas de purificación convencionales, afectando a más de 400,000 personas (Rock & Rivera, 2014). De manera análoga en sinaloa, las ARD y ARA no solo representan un riesgo biológico, sino que sus aportes de materia orgánica y fertilizantes alteran drásticamente los parámetros físico-químicos del agua (como caídas severas de Oxígeno Disuelto y variaciones de pH). Esto expone las limitaciones de los sistemas de reacción tradicionales y subraya la urgencia de contar con herramientas de alerta temprana [3].

Uso actual de IA y modelos de series temporales en el área:

Fundamentos del Aprendizaje Automático (Machine Learning): Es una rama de la inteligencia artificial que permite que los sistemas informáticos aprendan patrones a partir de datos sin ser programados explícitamente para cada tarea. El término se introdujo

formalmente por Arthur Samuel (1959) al definirlo como “la capacidad de las computadoras para aprender sin ser programadas de forma explícita” [5]. Como campo interdisciplinario, el aprendizaje máquina se apoya en la estadística, la teoría de optimización y la informática para diseñar algoritmos capaces de extraer las características más importantes de los datos proporcionados. Sus funcionalidades principales permiten abordar problemas de clasificación, agrupamiento (clustering), regresión y predicción [4].

Existen diversos métodos dentro de esta disciplina, siendo los más comunes el aprendizaje supervisado y el no supervisado. El modelo de aprendizaje supervisado opera mediante el entrenamiento con pares de datos de entrada (input) y salida (output); al contrastar esta información histórica, el algoritmo genera modelos matemáticos para clasificar o predecir nuevos resultados. Estos enfoques pueden aplicarse de forma global (uso general) o local (resolución de problemas particulares a partir de soluciones pasadas). Entre los modelos más relevantes desarrollados bajo este esquema se encuentran las máquinas de vectores de soporte (SVM), la lógica difusa, los árboles de decisión y las Redes Neuronales Artificiales (ANN) [4].

Algoritmos supervisados (Random Forest): Definido como un modelo de aprendizaje automático supervisado, este algoritmo se basa en la construcción de múltiples árboles de decisión. Su arquitectura combina la aleatoriedad de las características de los árboles con el principio de bagging. Esta es una técnica de aprendizaje en conjunto que combina múltiples modelos estadísticos individuales entrenados con subconjuntos aleatorios de datos; su finalidad es mejorar la precisión del algoritmo, minimizar la variedad y evitar el sobreajuste. Esta combinación le otorga al modelo una alta capacidad y robustez para realizar procesos complejos de clasificación y regresión [3].

Implementación de modelos de conjunto aditivo (XGboost): Se define como un sistema de aprendizaje automático escalable para el aumento de árboles. Propuesto por Chen y Guestrin (2016) este modelo avanza sobre arquitecturas anteriores al no entrenar todos los árboles de manera simultánea, sino utilizando un modelo de conjunto aditivo donde la predicción final es la suma de las predicciones de múltiples funciones de árbol independientes [5].

Fundamentos de Redes Neuronales Artificiales (ANNs): Las ANNs son un conjunto de unidades (neuronas) interconectadas que reciben datos de entrada y aplican ponderaciones

de forma que el valor resultante sea muy cercano a uno. Se definen como un conjunto de algoritmos inspirados en el proceso de aprendizaje humano, destacando por su capacidad para reconocer patrones numéricos ocultos en vectores de datos que pueden traducirse en imágenes, sonidos, textos o, de manera crítica para los ecosistemas hídricos [4].

Arquitectura de Redes Neuronales Recurrentes (LSTM): Derivado de las redes neuronales, una de las arquitecturas más robustas para la predicción de series temporales es la red LSTM (Long Short-Term Memory). Esta red supera a las RNN tradicionales al modelar dependencias a largo plazo mediante una estructura controlada por tres puertas (entrada, salida y olvido) que le permiten agregar, eliminar y actualizar el estado oculto o memoria.Según Hochreiter y Schmidhuber (1997), cada puerta emplea una función de activación sigmoidea (fórmula matemática que transforma cualquier número real en un valor que siempre está entre 0 y 1) y un elemento multiplicador para regular los pesos. Un componente crítico es la “puerta de olvido”, encargada de decidir qué información se descarta; si los valores del vector de salida son cercanos a cero, la información se elimina del estado de la celda, pero si son cercanos a uno, la información se mantiene [4].

5.2. Paso 3: Análisis de Hallazgos

¿Cuáles son los desafíos actuales en esta área?:

- **Presión ambiental y fuentes de contaminación complejas:** La red hídrica de Sinaloa enfrenta una presión ambiental severa generada por el escurrimiento de agroquímicos, las descargas de aguas residuales urbanas sin tratar y la filtración de residuos mineros. Esta contaminación constante por Aguas Residuales Domésticas (ARD) y Agrícolas (ARA) altera drásticamente los parámetros físico-químicos críticos, provocando caídas severas de Oxígeno Disuelto y variaciones abruptas de pH. Además, existe el desafío de lidiar con anomalías hidroquímicas, como la dispersión extrema de nitratos por el arrastre de fertilizantes hacia el agua y procesos acelerados de filtración de agua salada hacia los acuíferos en zonas agrícolas cercanas a la costa debido a la sobreexplotación.
- **Limitaciones físicas y logísticas del monitoreo tradicional:** El uso exclusivo de estaciones fijas de medición física resulta insuficiente para la escala del problema. El hardware tradicional sufre de acumulación de algas y materia orgánica y desgaste acelerado, mientras que los costos de operación y mantenimiento directamente en el

campo en zonas geográficas complejas son sumamente elevados. Estas barreras geográficas y económicas han provocado que tramos de difícil acceso en las zonas montañosas o canales de desagüe agrícola periféricos permanezcan históricamente sin supervisión.

- **Desfases temporales, datos discontinuos y gestión reactiva:** Los procesos de pruebas de laboratorio introducen desfases temporales que impiden actuar a tiempo ante emergencias ambientales. A nivel de bases de datos, existen retos significativos por datos faltantes o discontinuos derivados de fallas de transmisión, los cuales no pueden ser imputados con precisión por la estadística lineal convencional. En conjunto, estas limitantes operativas obligan a que la gestión hídrica actual se mantenga en un enfoque reactivo, exponiendo la urgencia de transitar hacia esquemas de alerta temprana preventivos.

¿Qué tan efectivas son las soluciones de IA existentes?:

Las soluciones basadas en árboles han demostrado ser altamente efectivas a nivel operativo. Por un lado, modelos como Random Forest controlan el sobreajuste mediante la agregación de múltiples árboles y manejan eficientemente variables predictoras interdependientes (como pH y conductividad). Al reducir la varianza mediante el promedio de estimadores, ofrecen alta precisión y son extremadamente robustos frente a valores atípicos causados por vertimientos industriales ocasionales.

Por otro lado, modelos avanzados como XGBoost incrementa esta efectividad al incluir una regularización matemática nativa que penaliza la complejidad excesiva, ayudando al modelo a aprender el patrón general de contaminación del sistema hídrico. Además, XGBoost maneja de forma altamente eficiente la realidad institucional de los datos dispersos; encuentra automáticamente divisiones para valores ausentes, permitiendo operar continuamente a pesar de los vacíos históricos generados por fallas en las estaciones de monitoreo físico [5].

¿Qué brechas existen que el proyecto busca abordar?:

A pesar de la efectividad de los modelos de ensamble, se presentan brechas analíticas y operativas significativas. La principal limitación de Random Forest es su incapacidad para anticipar eventos extremos nunca antes vistos; al promediar predicciones, presenta severas

limitaciones para calcular valores fuera del rango de los datos históricos suministrados, por lo que tendería a suavizar una crisis de contaminación sin precedentes hacia el promedio, fallando en la detección de la emergencia [5].

Por su parte, la brecha principal de XGBoost radica en su alta dependencia de la configuración de hiperparámetros (un ajuste incorrecto puede causar que ignore variables de alta toxicidad ocasional) y en su elevado costo computacional de memoria. Esta demanda de recursos representa una limitación técnica frente a la necesidad de implementar el modelo en dispositivos periféricos de bajo costo bajo un esquema de "sensores virtuales" [5].

Esta investigación aborda estas brechas al proponer el uso de redes recurrentes LSTM, cuya arquitectura está diseñada tanto para modelar el efecto de los contaminantes y anticipar anomalías fuera de los rangos históricos, como para adaptarse al monitoreo predictivo continuo y de alerta temprana.

5.3. Paso 4: Propuesta Técnica de Solución

Variables de entrada (X) del modelo:

El vector de características (X) está conformado por las mediciones ambientales disponibles y factores externos que influyen en la inercia hidrológica de la cuenca. Para dar cumplimiento a los objetivos planteados, estas variables incluyen:

- **Datos meteorológicos e hidrológicos**: Nivel de precipitación, temperatura ambiente y volumen de escurrimiento superficial.
- **Variables rezagadas:** Registros históricos de los días previos (t-1, t-2, t-n) correspondientes a los parámetros físico-químicos capturados por la red mínima de nodos IoT.

Variables objetivo a predecir (y):

Las variables de salida numérica continuas (y) que la red neuronal estimará para operar bajo el esquema de sensores virtuales son los parámetros críticos identificados previamente:

- Potencial de Hidrógeno (pH).

- Oxígeno Disueltos Totales (SDT).
- Turbidez (NTU).
- Concentración de nutrientes y compuestos antrópicos (Nitratos y Sulfatos).

Arquitectura de red neuronal propuesta (LSTM y modelos base):

La arquitectura de software se desarrollará en Python utilizando bibliotecas especializadas en tensores. Se conforma de:

1. **Capa de entrada**: Diseñada para recibir tensores tridimensionales (muestras, pasos de tiempo, características) correspondientes a la dinámica temporal del agua.
2. **Capas ocultas LSTM**: Núcleo del procesamiento que utiliza la estructura de puertas (entrada, salida y olvido) detallada teóricamente, empleando funciones de activación sigmoidea para regular qué información ambiental histórica se retiene o se descarta en el estado de la celda.
3. **Capa de Salida:** Una capa densamente conectada que proyecta las salidas continuas para cada variable *y*. Para validar la eficacia de esta red profunda, se establecerán como línea base de comparación modelos de ensamble Random Forest y XGBoost, ajustando sus hiperparámetros para procesar el mismo conjunto de datos estructurados en formato de tabla.

Cálculo y estandarización del Índice de Calidad del Agua (WQI):

Una vez que la red LSTM genera las predicciones numéricas de las variables objetivo (*y*), estos valores se integran mediante una suma lineal ponderada. Cada parámetro estimado se normaliza en una escala subíndice (curva de calidad) y se multiplica por un peso estadístico (Wi) que refleja su importancia relativa en la toxicidad acuática. El resultado consolida un puntaje único (WQI) que clasifica el cuerpo de agua en categorías operativas (Excelente, Buena, Pobre), sirviendo como detonador directo para el sistema de alerta temprana.

Métricas de evaluación del modelo (RMSE, MAE, R^2):

Para comparar rigurosamente el desempeño predictivo de la arquitectura LSTM frente a los modelos basados en árboles, se utilizarán las siguientes métricas de error estandarizados sobre el conjunto de validación:

- **RMSE (Error cuadrático Medio)**: Penaliza severamente los errores grandes o predicciones inusuales, siendo crucial para evaluar si el modelo logra anticipar eventos extremos de contaminación.
- **MAE (Error Absoluto Medio)**: Mide el margen de error promedio en la misma escala física de los parámetros, facilitando su interpretación operativa.
- **R^2 (Coeficiente de Determinación):** Indica la proporción de la varianza en los parámetros físico-químicos que es predecible a partir de las variables de entrada meteorológicas e hidrológicas; un valor cercano a 1 validará la efectividad de los sensores virtuales.

6. Agenda de Trabajo (Cronograma)

Fase / Periodo	Actividad Principal	Entregable / Resultado
Fase 1: Recopilación y Preprocesamiento de Datos (Mes 1 - Mes 2)	Extracción de registros históricos meteorológicos e hidrológicos. Limpieza de bases de datos, reconstrucción de datos faltantes y estructuración de la serie de tiempo en variables de entrada (X) y salida (y).	Dataset preprocesado, normalizado y estructurado en matrices temporales, listo para la fase de modelado analítico.
Fase 2: Desarrollo de Modelos Base (Línea comparativa) (Mes 3)	Programación en Python de los algoritmos Random Forest y XGBoost. Ajuste de hiperparámetros para procesar los datos estructurados en formato de tabla y evaluación preliminar.	Reporte técnico de métricas de error base que servirá como punto de comparación contra la red profunda.
Fase 3: Implementación y Optimización de la Red LSTM (Mes 4 - Mes 5)	Diseño de la arquitectura LSTM (capas y funciones de activación sigmoidea). Entrenamiento del modelo con variables rezagadas y prevención del sobreajuste (Overfitting) mediante la	Modelo de red neuronal recurrente (LSTM) optimizado, entrenado y evaluado rigurosamente mediante métricas RMSE, MAE y R^2.

	verificación del modelo con datos no vistos previamente.	
Fase 4: Integración del WQI y Cierre del Proyecto (Mes 6)	Integración de las predicciones físico-químicas continuas en la ecuación del índice de Calidad del Agua (WQI). Análisis comparativo final de los modelos de redacción del documento.	Sistema de sensores virtuales funcional y documento final de investigación concluido y revisado.

7. Conclusiones

La IA a demostrado la capacidad de automatizar las tareas y en el caso de la calidad ambiental no es la excepción ya que demuestra ser una herramienta clave para la protección ecológica, en lugar de limitarse a solo registrar cuando el agua sufre algún daño y en algún caso un daño irreversible la IA permite **anticiparse al problema.** Gracias a su capacidad de aprender patrones complejos y entender cómo se comportan los ríos y el clima a lo largo del tiempo, la IA actúa como un "traductor ambiental": toma datos sencillos como la lluvia y/o temperatura y predice cómo va a empeorar o mejorar el agua antes de que ocurra una emergencia.

Aportaciones principales de este proyecto:

- **Acceso real a monitoreo ecológico sin gastar millones:**
  El mayor freno para cuidar el agua en estados agrícolas como Sinaloa es que colocar sensores químicos en canal o río es carísimo y se descomponen rápido. Al usar redes LSTM como **sensores virtuales**, la IA resuelve este obstáculo económico haciendo las estimaciones mediante software.
- **Superar la falta de datos:**
  Aunque se caiga la señal o una estación falle, la IA es capaz de reconstruir la información faltante para no dejar "a ciegas" a las comunidades ni a las cuencas que casi nunca se revisan.
- **Cambiar la forma de actuar (de esperar a prevenir):**
  Al calcular el índice de calidad del agua (WQI) en tiempo real, la herramienta permite que las plantas de agua y los agricultores tomen decisiones antes de que los fertilizantes o las aguas negras generen un impacto irreversible en la salud de las personas o en los ecosistemas locales.

Líneas de trabajo futuro y recomendaciones:

Una vez validada la superioridad técnica de la red LSTM frente a los modelos base (Random Forest y XGBoost), se recomienda proyectar la integración de las salidas WQI en un panel de control interactivo que facilite la toma de decisiones a las autoridades ambientales. Asimismo, como trabajo futuro, se sugiere escalar la cobertura espacial del modelo, entrenando a la red con perfiles hidroquímicos de otras cuencas cercanas a la

Sierra Madre Occidental para evaluar la capacidad de adaptación de los sensores virtuales ante diferentes escenarios de carga agrícola, urbana y minera.

8. Referencias Bibliográficas

- [1] Beltrán, K. (2026, 14 agosto). Sinaloa en doble crisis, cantidad y calidad del agua. *Meganoticias*. https://www.meganoticias.mx/cdmx/noticia/sinaloa-en-doble-crisis-cantidad-y-calidad-del-agua/760244

- [2] Mendoza Aguilar, O. A., Bustos Terrones, Y. A., Rangel-Peraza, J. G., & Loaiza, J. G. (2025). Análisis de Calidad del Agua Subterránea de Sinaloa México. *Revista Veritas de Difusão Científica*, *6*(1), 2098–2116. https://doi.org/10.61616/rvdc.v6i1.501

- [3] Cruz Duque, M. E. (2025). *Evaluación de contaminantes orgánicos y parámetros físico químicos, mediante un modelo de predicción random forest con validación loocv, en el río Isinche para aguas de uso recreativo, Cotopaxi 2025* (Doctoral dissertation, Ecuador: Universidad Técnica de Cotopaxi). https://repositorio.utc.edu.ec/handle/123456789/14995

- [4] Quevedo, J. D. B. PROYECTO DE GRADO EVALUACIÓN DE RED NEURONAL RECURRENTE PARA PREDICCIÓN DE RIESGO POR SOx EN LA CIUDAD DE BOGOTÁ. https://www.researchgate.net/profile/Laura-Chaparro-17/publication/354608655_Evaluacion_de_Red_neuronal_recurrente_para_la_prediccion_de_riesgo_por_SOx_en_la_ciudad_de_Bogota/links/61422780dabc4638f12b69f4/Evaluacion-de-Red-neuronal-recurrente-para-la-prediccion-de-riesgo-por-SOx-en-la-ciudad-de-Bogota.pdf

- [5] (2026-06) Modelado predictivo del índice de calidad del agua en la cuenca del río Bogotá: un enfoque basado en machine learning y análisis de metales pesados. Recuperado de: https://hdl.handle.net/20.500.12495/20779